

OpenAffect-EEG：在标签资源匹配条件下审计 EEG 的额外价值

中文阅读版：与匿名英文投稿稿同步

2026 年 9 月 11 日

目录

摘要	2
1 引言	2
2 与已有评测的区别	3
3 资源匹配评测方法	4
4 受控实证	5
5 可执行资源与声明审计	8
6 讨论与局限	9
7 产物、伦理与结论	10
OpenAffect-EEG 中文补充材料母稿	12
最新覆盖分析：方法与完整结果	12
A. 数据来源与试次重建	18
B. 目标统一与标签边界	19
C. 划分协议	19
D. EEG 表征与模型	21
E. 刺激先验、残差与去偏模型	22
F. 身份探针	23
G. 统计方法	23
H. 补充结果解释	24
I. 发布与复现边界	26
J. 补充表与机器可读附件	26

英文题目: OpenAffect-EEG: Auditing EEG Added Value Under Matched Label Resources
定位: 评测方法与可执行审计工具。本文复用冻结 v9 的全部 EEG 预测, 新增五块统计验证与完整匹配增量图。匿名入口关键文件已于 2026-09-11 实测可访问; 发布版本需与本轮稿件核对。

摘要

将情感预测收益归因于 EEG, 需要无 EEG 对照获得相同的非 EEG 标签资源。与未校准基线相比的差值评价的是整个系统包。OpenAffect-EEG 将这一区别变成可执行评测: 固定测试试次, 分别控制参与者校准和重复刺激标签剂量, 保持群体训练规模, 并让 EEG 预测器与无 EEG 预测器获得相同标签。在 EmoEEG-MC 和街景评价任务上, 我们对频带功率回归、冻结 LaBraM 和标准 EEGNet 各两组设置完成 5×5 剂量网格, 共 1,500 个模型格点。最大剂量下, 某 LaBraM 设置相对未校准先验的系统收益在两任务分别为 +0.0961 和 +0.0587, 但匹配资源后的 EEG 差值变为 -0.0459, 描述性区间 $[-0.1098, +0.0139]$, 以及 -0.0186, 描述性区间 $[-0.0563, +0.0126]$ 。12 个任务一设置网格的五块 t 主区间均包含零。这不证明等价或 EEG 无信息, 而是说明在当前资源契约下, 观察到的系统总收益不能归因于 EEG。四类拓扑匹配模拟中, 主估计量“均匀网格平均”的覆盖率为 0.980–1.000; 单格范围仍是描述性的, 全部区间均条件于已拟合模型。配套检查器记录试次血缘、预测器资源和部署要求, 返回允许、阻断或不可验证。本文贡献是资源匹配评测对象及其可审计证据, 不是新编码器或情绪的因果分解。

1 引言

EEG 情感系统可能不仅使用当前 EEG, 还可能获得目标用户先前试次的评分、其他用户对同一刺激的评分, 或数据源提供的规范性刺激分数。部署时确实可得资源本身并不违规。归因问题发生在 EEG 系统获得这些资源, 而无 EEG 对照没有时: 如果前者得分更高, 差值同时包含 EEG 与额外标签访问。经典情感数据集反复呈现相同刺激并收集个体自评, 使这个问题具体存在 [文献: koelstra2012deap; daly2020musiceeg; openneuro_ds005540]。

本文只问一个诊断问题: 在完全相同的测试试次上, 如果 EEG 与无 EEG 预测器获得相同的参与者和刺激标签资源, 报告的收益是否仍然存在? 试次级防泄漏是必要条件, 但不能回答这个问题。测试试次即使从未进入训练, 两个预测器的校准标签仍可能不对等; 反过来, 资源匹配也不能把已经校准的参与者或已见刺激重新称为未见身份泛化。这是两种不同的科学检查。

OpenAffect-EEG 把该问题形式化为受控评测对象: 区分系统总收益、无 EEG 也能获得的校准收益和同资源 EEG 差值, 同时固定测试支持、控制群体训练规模并记录全部标签资源。减法本身不是创新, 创新对象是使减法两端可比较的可执行设计。该思路与 DAVE 等诊断基准“聚合分数可能掩盖实际贡献来源”的原则一致 [文献: radevski2025dave], 但本文处理的是 EEG 情感预测中的部署标签资源。

中心实证结果是: 两个任务中, 相对未校准先验的正向系统收益, 在无 EEG 对照获得相同校准标签后变为不确定差值。本文不据此声称 EEG 无信息, 而是说明当前正向总收益不能识别 EEG 的额外贡献。

1. **资源匹配的评测对象。**在固定测试支持上独立控制目标参与者校准和其他参与者对测试刺激的评分，以训练行替换和配对无 EEG 对照构成可解释比较，不声称因果身份或情绪解耦。
2. **受控实证审计。**三类 EEG 模型、两个任务的完整剂量网格、配对交叉 bootstrap 和已知真值模拟共同检验总收益能否经受匹配对照，以及评测器何时不可靠。
3. **可执行声明契约。**依据试次血缘、预测器资源、预处理与选择角色和测试哈希给出允许、阻断或不可验证；固定外部路径和合成错误展示“划分有效”与“部署声明受支持”的区别。

2 与已有评测的区别

EEGAIN 已统一数据、预处理、模型、划分、指标及预测日志 [文献: kukhilava2025eegain]。FMScope 已用参与者方向、频谱、层级和被试内诊断审计冻结表征 [文献: lin2026identitytrap]。用户校准、参与者一刺激联合留出和 EEG 工具箱也已经存在 [文献: li2021calibration; bendrich2022feature; liu2026eegemolib]。这些工作主要检查数据分区、模型或表征是否泛化；本文的分析单位不同，是固定测试支持上两个预测器获得了哪些标签，以及系统收益在匹配标签后还剩多少。

对象	已有评测主要问题	本文追加的比较对象
试次或身份留出	禁止重叠的试次或身份是否跨分区？	固定测试与群体训练规模时的标签资源剂量。
EEGAIN	统一流程下，各模型如何比较？	无 EEG 对照获得相同校准标签后，EEG 收益判断是否成立？
FMScope	编码了什么身份结构，移除后预测如何变化？	哪些标签资源支持当前对照与部署声明？
OpenAffect-EEG	给定资源契约后，EEG 额外价值是什么？	配对分数差及其资源、执行证据。

这是研究目标的限定比较，不是穷尽检索后的缺失功能断言。身份探针、线性移除、数据卡和来源哈希都不单独作为创新 [文献: lin2026identitytrap; gebu2021datasheets; mitchell2019modelcards; akhtar2024croissant]。

EEG 之外，诊断基准会把聚合分数分解为受控能力，以可配置的已知真值数据压力测试指标，并把统一协议和可复用代码与实证发现结合 [文献: radevski2025dave; tan2025syntsbench; ma2024imdlbenco; reuel2024betterbench]。OpenAffect-EEG 将这些基准属性用于一个领域特定估计对象：观测自评预测中资源匹配的 EEG 额外价值。剂量曲线、模拟和清单是支撑机制，不是各自独立的创新主张。本文不声称数据覆盖或分类精度超越 EEGAIN，也不声称识别 FMScope 讨论的生理机制。

3 资源匹配评测方法

3.1 试次图与资源契约

每个试次记录参与者、刺激、自评、情境和来源；窗口继承完整试次分区。对身份块 b ，固定测试为 T_b ，群体开发数据为 $D_b^{p,s}$ ，目标用户 i 的 p 个校准试次为 $C_{i,b}^p$ 。校准刺激不同于测试刺激。刺激剂量 s 为群体拟合中每个测试刺激拥有的其他参与者评分数。

$$\mathcal{R}_b(p, s) = (T_b, D_b^{p,s}, \{C_{i,b}^p\}_i, N_b, A_b, F_b, V_b).$$

N_b 为固定群体训练行数， A_b 为规范评分等额外标签资源， F_b, V_b 记录预处理拟合与模型选择试次。这是资源账本，不是身份信息量。

同刺激评分替换情境及目标尽量匹配的训练 donor，保持群体行数。个人校准不训练群体模型，仅估计拟合后的均值偏移。剂量集合确定且嵌套。替换仍改变训练组成，我们不保证全部分布属性相同；个人轴上的总标签量也不是固定，因为新增校准正是被测资源。

核心约束是：测试不进入拟合、选择或校准；模型和格点使用相同测试；实际剂量等于声明；目标用户不进入群体拟合；EEG 与无 EEG 对照获得相同非 EEG 标签。非零剂量表示身份已经暴露。规范评分在适用时单列保留，零刺激标签不等于没有刺激知识。会话、设备或上游预训练身份无法核实，就不认证严格隔离。

3.2 预测器与估计对象

P 使用拟合集刺激均值，缺失时使用已声明规范评分或拟合全局均值。PC 增加个人校准残差均值，不使用 EEG。E 在 P 上增加群体 EEG 残差预测；EC 以与 PC 相同的标签进行同类型均值偏移。另保留直接 EEG 对照。残差是相对指定先验的算术目标，不是私人情绪。

$$G_{\text{total}} = Q(EC) - Q(P), \quad G_{\text{cal}} = Q(PC) - Q(P),$$

$$\Delta_{\text{EEG}} = Q(EC) - Q(PC), \quad G_{\text{total}} = G_{\text{cal}} + \Delta_{\text{EEG}}.$$

Q 在同一测试支持上计算。等式是分数差恒等式，不是神经机制或 CCC 的因果分解。EC-P 可评价整个系统包，但资源不匹配时不能隔离 EEG 价值。个人剂量零时 $PC=P$ ，配对增量为 E-P。

主要汇总为五个固定身份块与完整 $\{0, 1, 2, 4, 8\}^2$ 网格的 EC-PC CCC 均值。MAE 是次指标，正差值表示误差增加。均匀权重是基准定义，不是真实部署频率。端点表不能取代主汇总，全部格点保留。

3.3 可观测执行检查

检查器读取身份表、执行记录及布尔约束，比较群体标签、校准、测试、预处理拟合和选择的 UID 集合。缺失证据返回不可验证，违反约束返回阻断，其余可观测检查才可能通过。通过也不认证身份真实性或上游预训练历史。

已校准用户可以满足测试试次隔离，却违反“未见参与者”声明。模型共用划分也可能因标签资源不同而不满足公平对照。普通交集检查器无法推断未提供的资源，不把新增字段检查称为普遍更高的错误检出率。

4 受控实证

4.1 评测覆盖

主分析包括 EmoEEG-MC 的 30 名合格参与者、42 个刺激、真实效价/唤醒度，以及 Urban 的 62 名参与者、56 幅街景、真实效价试次 [文献: openneuro_ds005540; openneuro_ds006850]。确定性身份块使每名参与者和每个刺激各进入测试一次，共得到 252 与 695 个固定测试试次。设计只测试五个对角身份块，而不是全部参与者一刺激组合。Urban 是外部评价任务，不是情绪诱发范式的严格复制；两个数据集都不是从未查看的确认队列。

每个任务包含频带功率 Ridge、冻结 LaBraM 和标准 Braindecode EEGNet，各两组有界设置。两个任务、五个身份块和全部 25 个剂量格点共形成 1,500 个模型格点结果，但这些格点不是独立观测。Ridge 设置改变候选正则网格，EEGNet 设置改变学习率。验证集选择超参数和训练轮数，群体重拟合使用训练与验证试次，但不使用测试或校准试次。200 份非恒定 EEGNet 选择/重拟合轨迹用于确认执行，不证明优化充分。完整预处理、覆盖和训练预算在附录。

4.2 正向系统收益不必是 EEG 收益

下表对全部配置使用相同的预定最大剂量。区间来自 EC-PC 的配对差值，不是两个独立区间端点相减；端点表用于解释比较对象，不替代完整网格平均。

任务	设置	EC-P	PC-P	EC-PC	配对 percentile 区间
EmoEEG-MC	Band-power R1	+0.1312	+0.1420	-0.0108	[-0.0429, +0.0219]
EmoEEG-MC	Band-power R2	+0.1318	+0.1420	-0.0102	[-0.0403, +0.0206]
EmoEEG-MC	LaBraM R1	+0.0961	+0.1420	-0.0459	[-0.1098, +0.0139]
EmoEEG-MC	LaBraM R2	+0.1325	+0.1420	-0.0095	[-0.0419, +0.0243]
EmoEEG-MC	EEGNet L1	+0.1400	+0.1420	-0.0020	[-0.0065, +0.0027]
EmoEEG-MC	EEGNet L2	+0.1420	+0.1420	0.0000	[-0.0040, +0.0043]
Urban	Band-power R1	+0.0639	+0.0774	-0.0135	[-0.0561, +0.0362]
Urban	Band-power R2	+0.0643	+0.0774	-0.0131	[-0.0398, +0.0199]
Urban	LaBraM R1	+0.0587	+0.0774	-0.0186	[-0.0563, +0.0126]

任务	设置	EC-P	PC-P	EC-PC	配对 percentile 区间
Urban	LaBraM R2	+0.0689	+0.0774	-0.0085	[-0.0373, +0.0172]
Urban	EEGNet L1	+0.0885	+0.0774	+0.0111	[-0.0147, +0.0360]
Urban	EEGNet L2	+0.0851	+0.0774	+0.0078	[-0.0064, +0.0252]

在 EmoEEG-MC 的 LaBraM R1 中, EC 相对未校准先验 P 的收益为 +0.0961; 相同校准标签使无 EEG 预测器提高 +0.1420, 故匹配 EEG 差值为 -0.0459, 区间 [-0.1098, +0.0139]。Urban 对应值为 +0.0587、+0.0774 和 -0.0186, 区间 [-0.0563, +0.0126]。系统层面的点收益为正, 但 EEG 特有差值没有被建立为正。这是资源匹配实际改变的判断。

主要的均匀网格平均 EC-PC CCC 如下, 报告五个身份块对应的 block-t 主区间 (df=4)。

设置	EmoEEG-MC: 均值 [区间]	Urban: 均值 [区间]
Band-power R1	-0.0069 [-0.0333, +0.0221]	-0.0060 [-0.0432, +0.0376]
Band-power R2	-0.0091 [-0.0306, +0.0145]	-0.0069 [-0.0312, +0.0216]
LaBraM R1	-0.0320 [-0.0676, +0.0104]	-0.0173 [-0.0482, +0.0112]
LaBraM R2	-0.0137 [-0.0376, +0.0139]	-0.0035 [-0.0238, +0.0150]
EEGNet L1	-0.0001 [-0.0040, +0.0047]	+0.0073 [-0.0056, +0.0217]
EEGNet L2	+0.0003 [-0.0028, +0.0040]	+0.0086 [-0.0043, +0.0215]

12 个任务—设置组合的 block-t 主区间均包含零, percentile、basic 和旧 t-normal 敏感性分析不改变这一判断。由于没有预设等价界值, 本文不把它写成模型等价、普遍反转、EEG 无信息或未来方法的能力上限。次要 MAE 中, LaBraM R1 在两个任务的主区间下均显示误差增加; 其他配置不确定或对区间方法敏感。附录报告全部 CCC 与 MAE, 而不是只选择显著行。

主分析后补做的稳健性检查仍支持这一有界解释。替代身份分块并完整重拟合后, Emo/Urban 任一点估计的最大位移为 0.0135/0.0154, 12 个区间均跨零。四个资源角点上的三组 EEGNet 初始化中, 全部 12 个任务—设置—运行区间跨零, 最大点估计跨度为 0.0097。只解冻最后一个 transformer block 与归一化层的 LaBraM 残差微调在 Emo/Urban 分别为 -0.0110 [-0.1041, +0.0820] 和 -0.0404 [-0.1159, +0.0351]。这些是看到主结果后执行的敏感性分析, 不是独立队列, 也不构成无条件重训练区间。

匹配对照为什么具有实质影响? 从双轴零剂量出发, 八个目标用户校准试次使无 EEG 的 PC CCC 在 Emo/Urban 分别提高 +0.2036/+0.1564; 每个测试刺激加入八个其他参与者评分后, 分别提高 +0.4907/+0.3408, 两种区间构造均为正。“标签有用”并不新颖, 但它相对匹配 EEG 差值的量级说明, 标签访问不对等会改变系统分数的归因。

4.3 不确定性与评测器有效性

参与者和刺激交叉 bootstrap 对所有配对预测器、格点和身份块使用同一组重采样重数。2,000 次抽样中, EmoEEG-MC 有 1,985 次有效, Urban 有 2,000 次有效。主区间使用交叉 bootstrap 标

准误和五块聚合对应的 t_4 临界值；percentile、basic 和旧的块内 t-normal 是敏感性分析。全部构造都条件于已拟合预测，不包含完整重训练不确定性。单格范围和剂量族带不支持已校准的单格筛选或全部模型多重比较。

同一分析器还在具有解析总体 CCC 的预设高斯交叉模拟上接受检验。16 个 trial-signal 设置各 100 次重复时，正向检出率为 0.85–1.00，点区间覆盖率为 0.92–1.00；仅标签预测器精确返回零，16 个独立噪声设置在有限模拟中没有产生正向检出。新的 300 次重复检查在 32 名参与者、24 个刺激时给出 0.933 的 percentile 覆盖，但在 8 名参与者、6 个刺激时最低降到 0.837。模拟支持评测器的预期方向行为，也明确暴露小支持下的失败边界；它不保证任意小 EEG 数据集都达到名义覆盖。

4.4 范围检查与保留的不利证据

旧 EmoEEG-MC 和 MusicEEG 响应面、紧凑与标准 EEGNet、CBraMod、LaBraM 随机对照、冻结 EMOD 和校准变体均保留在附录，但它们使用不同支持或协议，不是主网格的重复证据。旧 MusicEEG LaBraM 全网格平均增量为 +0.0182，区间 [-0.0161,+0.0452]，是不确定的听觉结果；Urban 不能把它删除或替代。资源条件模型选择同样没有稳定平均 CCC 收益。

身份探针和子空间扰动只是表征诊断，不提供因果证据。ds006866 只能研究条件暴露，因为图片身份不可用；DENS 受缺失限制；SEED-V 是授权聚合补充，不是公开重分发基准。EMOD 修复后的单次学习检查既不是原任务完整复现，也不能作为反对 EMOD 的证据；mdJPT 没有完成数值审计。这些记录限定模型和领域覆盖，不提升为正文主证据。

当前网格的完整展示与部署解释

新增图保留 12 个完整网格的 300 个单元，四角 (0,0)、(8,0)、(0,8)、(8,8) 的 48 个比较另有完整 CSV。Urban EEGNet L2 的所有单元点估计为正，范围为 +0.0003 至 +0.0177；正向点估计不等于有充分证据支持增益。300 个单元没有正向 pointwise CCC 区间，Urban LaBraM R1 有两个负向 pointwise 区间，但其剂量族同时带均跨零。这是已看过数据后的描述，不是新增确认性检验。

资源匹配不保证每个模型同样充分地利用标签。固定刺激剂量 s 时， P 与 EC 已共享重复刺激评分， $EC-P$ 中不匹配的是参与者校准资源；改变 s 是在不同共享刺激资源下评价配对模型，不是刺激信息的纯因果效应。均匀网格平均代表规定的基准汇总，不代表最优部署政策。真实部署还需考虑校准时间、评分取得方式、刺激重复概率和 EEG 采集成本；不能平均各格区间端点获得加权汇总区间。

已有真实任务的训练诊断

每个任务的直接和残差分支各有 50 条 EEGNet 拟合记录。Emo 分别有 12 和 10 条选中第一轮，所选轮数中位数为 18 和 17.5；Urban 分别有 8 和 7 条，中位数为 11 和 7.5。四组训练目标均有正的中位下降量，分别为 0.1104、0.1162、0.1922、0.2080。这些是既有结果的整理，没有重新训练；它们不支持“全部网络停在初始拟合”的解释，但不能证明最优调参或明确的测试 EEG 信号。

历史 compact/standard EEGNet、收缩校准与 SEED-V 修复保留各自支持范围，不能冒充同任务完整 SOTA 验证。

与主分析一致的五块统计验证

主分析先在每块内计算 CCC，再平均身份块和剂量。Emo 每块仅 6 人、8 或 9 个刺激；Urban 每块为 12 或 13 人、11 或 12 个刺激。总体参与者数不能自动证明这种小块 CCC 平均的区间可靠。新增实现匹配实际五块完整对角拓扑、目标维数和全部 25 个剂量单元，复用生产分析器的全局交叉身份权重，任何块无效时均不删除该块补救。单元点估计、平均值、区间端点和有效重复数已与生产分析器通过数值一致性测试。

冻结方案每任务、每种场景运行 300 个新随机重复，每重复 2,000 次 bootstrap，保留 label-only、trial-signal、participant-constant 和 independent-noise 四场景。主 block-t 保留同一交叉 bootstrap 标准误，以五个身份块作为聚合单位（df=4）；percentile、basic 和旧 t-normal 保留为敏感性方法。该修正在早期诊断失败后引入，但临界值由估计量拓扑决定，没有使用真实 EEG 效应的符号或大小。模拟不复刻实际 EEG 分布、跨块训练资源依赖或重训练随机性。

五块模拟已完成全部 2,400 个重复，失败为零。原始三种候选方法有 187,200 行，派生 block-t 另有 62,400 行；这些行包含同一模拟的格点和均值，不能当作独立重复数。block-t 对主均匀网格平均的覆盖率在 trial-signal 下为 Emo 0.993、Urban 1.000，在 participant-constant 下为 0.980/0.983，两个无信号检查均为 1.000；Wilson 下界为 0.957–0.987。最差单格覆盖仍只有 0.917，因此校准证据只支持主均值，不支持单格推断。

任务	场景	Block-t 覆盖 [MC 区间]	Percentile	Basic
Emo	试次信号	0.993 [0.976,0.998]	0.900	0.983
Emo	参与者恒定信号	0.980 [0.957,0.991]	0.903	0.910
Urban	试次信号	1.000 [0.987,1.000]	0.927	0.977
Urban	参与者恒定信号	0.983 [0.962,0.993]	0.970	0.920

仅标签场景的区间退化为零，覆盖为 1 是代数检查；独立噪声在有限运行中无正向区间，不等于对所有零假设控制误报。block-t 证据局限于四类高斯信号和固定拟合的均匀网格平均，不能外推到真实 EEG 分布、任意信号族、单格选择或重训练不确定性。全文不作等价声明；资源分解的代数恒等式和描述性配对点差值不依赖显著性阈值。

5 可执行资源与声明审计

执行记录	观察	对声明的影响
LibEER 无验证集分支	测试数组赋给验证	阻断“模型选择未用测试试次”

执行记录	观察	对声明的影响
EEGain 窗口验证划分	同一试次标记进入训练与验证	违反额外验证试次隔离；仍可满足留测试用户
资源不匹配例	仅 EEG 获得个人标签	即使划分干净，也不支持同资源对照
来源缺失例	未提供预处理拟合试次	不可验证，不默认通过

外部案例固定官方提交并执行实际划分函数；每个合格 Emo 试次生成三个标记窗口用于追踪，不当作独立实测 EEG。LibEER 另执行精确无验证集分支，但不训练外部分类器。普通交集检查器也能发现这些划分违规。新增评测对象是执行证据是否支持所请求声明：同一执行轨迹可以阻断“验证试次隔离”，同时允许较窄的“测试参与者留出”。资源匹配还要求记录预测器输入，而训练—测试交集无法推断这些输入。

20 个原生或限定声明案例包含 10 个请求规则违规和 10 个干净或正确限定案例，两种检查器均给出对应决定。另 70 个开发者资源案例为 50 个人工违规、10 个干净、10 个缺失来源，资源检查器分别阻断、通过、保留不确定。这是有限规则覆盖，不是文献总体检出率或独立用户研究，不把人工错误归咎原工具，也不据路径否定论文分数。

无需 EEG 的入口为 `python -m openaffect_eeg.workflow_audit`，提供 `trials`、`execution`、`contract` 和 `output` 参数。报告列出失败规则与 UID 差异。合成例涵盖资源匹配、不匹配、来源缺失和虚假未见用户。原始训练使用另一组有许可数据命令。哈希只证明字节血缘，不证明身份和上游训练历史真实。

机器可读规则目录将检查分为试次血缘、身份留出、预处理/选择、资源匹配和固定测试支持五类；每类均记录规则依据、所需证据、允许、阻断、不可验证示例及不支持的推论。同一 EEGain 执行记录在五折中对严格“训练与验证试次隔离”声明全部阻断，对较窄的“留测试参与者”声明全部允许；固定函数、trial 集和输出均未改变。因此修复的是可支持的声明，不是模型分数。

6 讨论与局限

落实的是收益归属规则。没有资源一致性时，超过未校准先验不等于 EEG 的额外价值。实验表明，这个区别会改变当前两个任务中的数值判断，但未证明旧论文都采用相同的不匹配对照。正确限定的零校准跨被试结果仍然有意义；资源账本只是把它的适用范围写清楚。

本研究的真实 EEG 预测比较说明如何修正收益归属；外部 EEGain/LibEER 代码案例说明如何修正执行声明，未复现外部分类器分数。二者支持预防性评估 workflow，不能量化已发表 EEG 收益中有多少来自资源不匹配。

实用能力。比较编码器时固定测试和标签；报告用户校准预算及性能；复现时区分划分正确与比较公平。这是已实现 workflow，不等于广泛采用、独立使用体验、模型选择改进或 EEG 经济回报。无 EEG 对照也不是临床验证替代设备。

证据边界。这是回顾性、有限身份对与有界训练分析，不覆盖所有微调。刺激注入可能改变验证侧身份关系，不能称全验证过程身份未见。两轴是试次图资源操作，不是潜在情绪随机因果干预。

额外先验与未知预训练暴露必须显式保留。均匀平均可掩盖异质性，故保留全表；固定拟合区间有小簇局限。不同任务的诱发和标签定义不同，不能推广到全部 EEG 情绪模型。

7 产物、伦理与结论

代码、聚合、划分规则、版本、模型与数据卡、合成例和证据哈希已形成经匿名扫描、带哈希清单的审稿归档。匿名入口 <https://anonymous.4open.science/#/r/OpenAffect-EEG-1815/> 的 README、安装配置、验收脚本和核心检查器已于 2026-09-09 无登录访问成功。版本同步是另一项检查。作者已报告同事跑通工具，此项与开发者 clean-run 分开记录，不扩大为独立复现全部 EEG 训练。原始 EEG、个体特征和预测、刺激与权重不重分发。Urban 许可证文字不一致如实记录。身份探针不得识别人，自评预测不等于诊断或读取私人情绪。

OpenAffect-EEG 提供固定支持、资源匹配的比较对象，以及可观测假设检查。中心结论是：**系统总收益与 EEG 额外价值应分别报告，每个比较须带有可验证资源条件。**不确定增量保持不确定，评测贡献不要求 EEG 必须成功，也不要求 EEG 必须失败。




图 1: 完整匹配 EEG 增量网格。数值与色标均为 CCC 差值乘以 1000，四舍五入的零不表示精确相等。全部 12 个网格和 300 个单元均保留；每格为五个身份块内配对差值的平均。完整条件区间见随附 CSV。

OpenAffect-EEG 中文补充材料母稿

与资源匹配修订版正文配套。下列最新覆盖分析对应 v9 证据；A 节及其后保留历史实验，不把旧协议与新身份块混为同一实验。历史章节中的主分析指当时的冻结计划，不替代当前正文主汇总。

最新覆盖分析：方法与完整结果

来源和覆盖

EmoEEG-MC 使用 1.0.7 快照，30 名合格用户、42 个刺激、1,260 个可用试次。Urban 使用 ds006850/1.0.0，62 名用户、56 幅图片、3,471 个真实效价试次，不把其他量表复制成效价或唤醒度。一个已确认截断的源记录在预测检查前排除 [文献: openneuro_ds005540; openneuro_ds006850]。Urban 的 dataset_description 声明 CC0，同快照 README 写 CC BY 4.0；保留冲突，不重新发布原始数据或刺激。

用设计种子 20260908 的 SHA-256 顺序将参与者和刺激各分五块。块 b 对角身份对为测试，下一块为验证，其余块为初始群体训练。每身份测试一次不等于所有试次对测试。同刺激标签注入可以使用验证块用户，只有测试用户始终排除于群体拟合，不能把注入后的全部验证身份说成未见。

有界训练和预处理

Ridge R1 alpha 网格为 0.1/1/10/100，R2 为 1/10/100/1000。频带功率与 LaBraM 均采用两网格；Emo 历史键 de 实为 channel_log_bandpower，不另称独立 DE 实现。EEGNet 固定 Braindecode 1.2.0，F1=8、D=2、F2=16、dropout=0.25，AdamW weight decay=0.0001，batch size=128，最多 100 轮、patience=15。L1/L2 学习率 0.001/0.0001。验证 MAE 选轮数，训练加验证重拟合。个人校准只改拟合后偏移，不训练网络。

Emo 使用既有 100 Hz 原始试次和十秒 EEGNet 裁剪。Urban 仅 64 个 EEG 通道，物理单位伏，排除 ECG/GSR，平均参考、500 到 100 Hz 多相重采样，使用图片后、评分前的三秒。测试窗口预测在试次内平均。下游学习归一化不读测试或校准。LaBraM 使用记录的 checkpoint、单位与通道适配，上游身份不认证。

全部主要和次要汇总

下列同源表格未重新训练模型。V13 主区间从同一冻结预测重新执行交叉 bootstrap，并按五块聚合使用 df=4；全部 300 个聚合格点检查 $EC-P=(PC-P)+(EC-PC)$ ，最大数值误差小于 $1e-12$ ，只验证分数恒等式。区间来自配对差值，不是独立区间端点相减。

EmoEEG-MC: EC-PC CCC

配置	平均差值	Percentile 95%	t-normal 95%
Band-power R1	-0.0069	[-0.0333, +0.0221]	[-0.0435, +0.0298]
Band-power R2	-0.0091	[-0.0306, +0.0145]	[-0.0385, +0.0202]
LaBraM R1	-0.0320	[-0.0676, +0.0104]	[-0.0842, +0.0201]
LaBraM R2	-0.0137	[-0.0376, +0.0139]	[-0.0466, +0.0192]
EEGNet L1	-0.0001	[-0.0040, +0.0047]	[-0.0060, +0.0059]
EEGNet L2	+0.0003	[-0.0028, +0.0040]	[-0.0042, +0.0048]

有效 bootstrap 次数: 2,000 次中的 1985 至 1985 次。

EmoEEG-MC: EC-PC MAE

配置	平均差值	Percentile 95%	t-normal 95%
Band-power R1	+0.0047	[-0.0004, +0.0099]	[-0.0019, +0.0113]
Band-power R2	+0.0039	[+0.0000, +0.0078]	[-0.0013, +0.0090]
LaBraM R1	+0.0151	[+0.0061, +0.0242]	[+0.0034, +0.0269]
LaBraM R2	+0.0065	[+0.0016, +0.0112]	[+0.0001, +0.0129]
EEGNet L1	+0.0002	[-0.0008, +0.0013]	[-0.0012, +0.0016]
EEGNet L2	+0.0002	[-0.0004, +0.0009]	[-0.0007, +0.0011]

有效 bootstrap 次数: 2,000 次中的 1985 至 1985 次。

Urban Appraisal: EC-PC CCC

配置	平均差值	Percentile 95%	t-normal 95%
Band-power R1	-0.0060	[-0.0432, +0.0376]	[-0.0519, +0.0398]
Band-power R2	-0.0069	[-0.0312, +0.0216]	[-0.0370, +0.0233]
LaBraM R1	-0.0173	[-0.0482, +0.0112]	[-0.0522, +0.0175]
LaBraM R2	-0.0035	[-0.0238, +0.0150]	[-0.0257, +0.0187]
EEGNet L1	+0.0073	[-0.0056, +0.0217]	[-0.0080, +0.0226]
EEGNet L2	+0.0086	[-0.0043, +0.0215]	[-0.0059, +0.0230]

有效 bootstrap 次数: 2,000 次中的 2000 至 2000 次。

Urban Appraisal: EC-PC MAE

配置	平均差值	Percentile 95%	t-normal 95%
Band-power R1	+0.0063	[-0.0012, +0.0144]	[-0.0024, +0.0151]
Band-power R2	+0.0037	[-0.0009, +0.0082]	[-0.0015, +0.0089]
LaBraM R1	+0.0091	[+0.0036, +0.0148]	[+0.0027, +0.0156]
LaBraM R2	+0.0038	[+0.0003, +0.0073]	[-0.0002, +0.0078]
EEGNet L1	+0.0027	[-0.0009, +0.0068]	[-0.0016, +0.0071]
EEGNet L2	+0.0012	[-0.0013, +0.0041]	[-0.0019, +0.0043]

有效 bootstrap 次数：2,000 次中的 2000 至 2000 次。

无 EEG 资源效应与统计边界

从零剂量出发，PC 个人剂量效应：Emo +0.2036 [0.0955, 0.3116]、Urban +0.1564 [0.0492, 0.2637]；刺激剂量效应：+0.4907 [0.3581, 0.6233]、+0.3408 [0.2161, 0.4655]；联合效应：+0.6327 [0.4810, 0.7844]、+0.4181 [0.2928, 0.5435]。这里是启发式 t-normal 敏感性区间，对应 percentile 也为正。这不同于正文在固定刺激剂量的 PC-P 比较。

重采样共享参与者和刺激重数，块内计算再跨块平均，不把网格预测当独立样本。小簇覆盖诊断与无效次数限制解释。主 block-t 只对均匀网格平均获得拓扑匹配支持；固定拟合区间不是重训置信度或等价检验，单格范围和剂量族带不统一控制所有模型和次指标。

主分析后的稳健性检查包括：更换身份分块并完整重拟合六个设置；在原分块四角上采用三组 EEGNet 初始化；以及只解冻 LaBraM 最后一个 transformer block 和归一化层、通过验证集选 epoch 后在训练加验证上重拟合残差头。替代分块的最大点位移为 Emo 0.0135、Urban 0.0154，12/12 区间跨零；三组 EEGNet 初始化的最大点跨度为 0.0097，12/12 区间跨零；LaBraM 微调为 -0.0110 [-0.1041,+0.0820] 与 -0.0404 [-0.1159,+0.0351]。这些检查使用同一已查看数据，不是新确认队列，也没有覆盖全部 5×5 微调面、任意优化器或任意 checkpoint。

已知真值评估器压力测试

在解释 EEG 结果前，我们先在已知构造结果上检验估计器。v6 oracle 套件包含 16 个设置、每项 100 次重复：

生成机制	记录行为	解释边界
仅标签恒等式	精确为零	仅为代数负对照
独立噪声	16 个设置均无正向检出	有限模拟证据，不证明假阳性率严格为零
trial 变化信号	检出率 0.85–1.00，覆盖率 0.92–1.00	只说明这些设置能检出注入信号

生成机制	记录行为	解释边界
参与者常数信号	校准均值抵消；v6 最低覆盖 0.82	暴露有限簇弱点，不作生物或因果解释

v7 有限簇研究计划 9,600 次，9,584 次有效，16 次被预设支持规则拒绝。目标 32×24 簇设置下，percentile、basic、t-normal 的覆盖率分别为 0.933、0.930、0.957；刻意缩小到 8×6 簇时，最低值分别为 0.837、0.820、0.940。t-normal 往往更宽，因此只作为敏感性分析，不宣称它普遍校准。

规则依据与三态决定

检查器只根据可观测证据给出允许、阻断或不可验证，缺少来源时保留不可验证，不默认通过。

规则族	必需证据	代表性边界
试次血缘	每个分区的 trial UID	同一试次派生窗口重复会阻断试次隔离声明
身份留出	参与者与刺激 UID	重叠只阻断对应身份声明，不自动否定其他声明
预处理与选择	拟合和选择所用 UID	缺失来源返回不可验证
资源匹配	每个预测器可访问的标签	校准标签不等会阻断 EEG 额外价值声明
固定测试支持	每个比较器的测试哈希	测试支持不同会阻断配对比较

完整目录逐项记录依据、所需证据、允许/阻断/不可验证示例以及不支持的推论。它不认证数据真实性、上游预训练历史或因果有效性。

外部来源与复用

EEGain 提交 d6892f5586181f345969651a9baedabd828bb1c5，执行 EEGDataLoader.split_train_val。LibEER 提交 dddff9776dbdae21195fe320dff0a5ba61628a18，执行 get_split_index、index_to_data 及 EEGNet_train.py 第 100 至 102 行精确分支。文件哈希、代码范围和案例类型在 external_audit/public_summary.json。标记窗口不是独立 EEG，分支不能推断原文分类分数。

同一 EEGain 记录满足留测试用户，但可违反额外验证试次隔离。修复是限定声明，或在确需隔离时先分完整试次再生成窗口。LibEER 显式训练/验证/测试路径通过所检查条件，无验证集回退不能当独立验证。

机器记录 [submission_closure_v11/external_claim_repair.json](#) 在五个 EEGain 折上验证了严格声明全部阻断、限定声明全部允许；两种判断使用相同的固定提交、函数、trial 集和执行输出。它证明工具能把执行证据映射到更窄的可支持声明，不改变也不重新估计模型结果。

运行 `pythonscripts/run_workflow_contract_toy.pytoy_contract` 可生成资源匹配、不匹配、来源缺失和错误用户声明，再用 `python -m openaffect_eeg.workflow_audit` 检查相应 JSON。这是开发者运行，不冒充独立组员验收，也不认证恶意伪造的血缘。

已审批历史图保留

本工作使用 AI 辅助协议和代码草拟、调试、文献初筛、分析支持及写作。EEG 预测、bootstrap 和契约决定由记录的数值模型与确定性程序生成，不由大模型充当情绪预测器或审计裁判。自动检查和代理运行不代表独立人工审查；作者仍须核查来源、解释结论并批准投稿。

这些图仅更新视觉编码，不改变数值来源，也不改标为最新覆盖分析。当前资源匹配结论以正文自动生成表格为准。




图 1：原始试次优先评测契约。原四个数据源与协议边界，Urban 和最新配对资源在方法中单列。

Identity-exposure response surfaces

Same fixed joint test trials in every cell; higher doses use labelled deployment resources




图 2：原始固定测试响应面。Emo 和 MusicEEG 总预测 CCC，不是 EEG 增量；MusicEEG 保留原可行网格。




图 3：身份解码性审计。柱为五个固定种子的均值，误差线为样本标准差，散点保留每个种子；观测与置换探针反映可解码信息，不证明预测器使用身份。




图 4：参与者子空间扰动。零移除、PCA 与随机方向均保留，不作潜在情绪解耦解释。




图 5：条件级外部审计。预测与探针柱保留五种子均值、样本标准差和单种子散点，中间面板为配对 bootstrap 95\% 区间；ds006866 无图片身份，不支持留图片声明。

A. 数据来源与试次重建

A.1 版本固定来源

OpenAffect-EEG 使用以下 OpenNeuro 快照，而不是浮动的“最新版”：MusicEEG ds002721 1.0.3、DENS ds003751 1.0.6、EmoEEG-MC ds005540 1.0.7，以及外部验证 ds006866 1.0.0 [文献: openneuro_ds002721; openneuro_ds003751; openneuro_ds005540; openneuro_ds006866]。每个源文件均通过快照清单、字节数或 annex key 检查；派生 trial 表另记录输入哈希。

4 个数据集共重建 39,642 个试次，涉及 279 名数据集内合格被试，其中 38,369 个试次具有完整且可统一的连续情绪目标。核心 3 个刺激诱发数据集包含 131 名被试、4,135 个试次和 369 个数据集内合格刺激身份；2,865 个试次进入带完整自我报告的核心监督评测。

A.2 MusicEEG

MusicEEG 记录参与者聆听电影音乐片段时的 EEG 与八项自我报告 [文献: daly2020music EEG]。基准保留 1,240 个任务试次。公开事件流没有直接给出规范化音频文件名，当前 stimulus_uid 由事件码减去固定偏移后与公开 OSF Set 1 对齐。该映射满足所有试次存在唯一候选码、候选均落入资源编号范围、每个编号同时存在音频与规范评分等检查，但因公开 README、事件说明和早期论文对素材集合的描述并不完全一致，状态被记录为 audited_inference，而非 source_verified。

MusicEEG OpenNeuro 快照声明 CC0；配套 OSF 音乐资源声明 CC BY 4.0。公开基准不包含音频文件，只发布来源指针、推断状态和分割所需身份元数据。

A.3 DENS

DENS 使用自然视频诱发情绪，并收集连续维度与类别评分 [文献: asif2023dens]。事件与行为数据按规范化刺激名称连接，而非按行号连接；缺失行为记录的事件被保留并标为无标签。源.set 头声明的信号长度与多数公开.fdt 文件字节数不一致，完整时间窗只对部分试次可读。特征提取不会补零、循环读取或将缺失二进制样本估算为有效 EEG，而是通过独立可用性掩码记录。365 个有标签试次中仅 162 个具有可用特征，缺失率为 0.5562；7 名被试完全缺失，可用与缺失试次的效价标准化均值差为 0.1895。因此所有 DENS 结果均明确标为 complete-case 分析。

公开事件使用 20 个本地刺激名，但源快照没有 README 所述的 stimuli/ 与 code/ 目录，论文所指 AFDI 条目也无法与这些本地身份可靠对应。因此基准仅把公开事件中的本地身份用于组划分，不声称已恢复原始影片文件。DENS 的 dataset_description.json 声明 CC0，而仓库 LICENSE 与 README 分别给出 ODbL/DbCL 条款；在矛盾解决前，任何派生发布都按更保守的署名与共享要求处理。

A.4 EmoEEG-MC

EmoEEG-MC 同时包含视频观看和文本引导想象，适合方向性跨情境评测 [文献: xu2025em EEG]。公开行为导出的 video_name 对部分参与者被同一错误值重复填充，不能按行

位置与 EEG 试次连接。基准只保留可验证全局刺激码的监督子集，其余试次仍留在 provenance 表中，但标签状态设为不可用。可监督子集的情境方向又使用源 EDF 触发类型进行交叉验证。

公开 DE 文件、reorder 数组、CBraMod 与 LaBraM 特征均不进入匿名发布包。基础模型输入仅使用与监督子集一一对应、哈希核验并且数值有限的试次。数据快照声明 CC0；模型代码与 checkpoint 的许可和哈希分别记录，避免把数据、代码和权重视为同一许可对象。

A.5 ds006866 外部验证

ds006866 研究社会/非社会图片、负性观看、中性观看和认知重评条件下的自我报告与神经生理反应 [文献: maka2026discrepancy]。基准包含 148 名被试并重建 35,507 个图片呈现试次，其中 35,504 个试次具有完整效价和唤醒度评分。公开事件表能够恢复实验条件和社会/非社会内容情境，却不包含 trial 级图片身份；EEGLAB 标注也不能补回该字段。因此本数据集支持严格留被试、留内容情境及被试-情境联合留出，但留图片刺激与被试-图片双重留出明确标为 blocked_by_source_metadata。

OpenNeuro 快照声明 CC0。相关 OSF 刺激元数据为 CC BY 4.0，但原始图片可能来自具有独立使用约束的素材库；匿名发布包不包含图片或可替代图片分发的媒体索引。

B. 目标统一与标签边界

MusicEEG 使用 pleasant 与 energetic 自我报告作为效价和唤醒度；DENS、EmoEEG-MC 与 ds006866 使用各自发布的 valence/arousal 字段。MusicEEG、DENS 和 ds006866 的原量表为 1–9，转换为 $(x-1)/8$ ；EmoEEG-MC 的原量表为 0–7，转换为 $x/7$ 。原始值、量表名和归一化表达式均保留在 trial 表或结果 provenance 中。

统一连续目标是参与者的试次级自我报告。名义刺激类别、材料规范评分和实验条件均只能作为输入、分层或审计变量，不能替换个体自我报告后仍被称为同一目标。缺少任一连续目标的试次保留元数据，但不进入需要完整效价与唤醒度的监督指标。

C. 划分协议

C.1 单因素与乐观对照

完整试次在任何窗口化之前分配。试次随机、留被试和留刺激协议均在每个数据集内使用 70/10/20 的训练、验证、测试比例；小身份集合至少为验证和测试各保留一个组。试次随机只隔离 trial_uid，并额外记录被试与刺激在训练和测试间的重叠数量。留被试和留刺激分别要求对应身份交集为零。

C.2 双重留出

被试与刺激分别按 60/20/20 分配。仅当两种身份落入同一分区时保留该试次；其余跨分区边被明确标为 `excluded`。这一策略在稀疏被试-刺激图上牺牲部分覆盖，以实现真正的双冷启动。比例在实验前确定，原因是更小的验证身份比例无法为多个种子提供足够验证试次。

C.3 样本支持匹配的身份重叠对照

对每个双重留出种子固定完全相同的测试 trial UID，并保持训练与验证行数分别相等，再从可用训练边中采样，使测试被试和测试刺激均在拟合分区出现。该对照保持测试支持与样本量不变，改变训练侧身份重叠及其图结构；它估计对这一训练组成变化的条件敏感性，不识别身份单因素的因果影响。

C.4 跨情境与留数据集

EmoEEG-MC 的方向性迁移先按被试划分，再只允许源情境被试进入训练与验证、目标情境的未见被试进入测试。视频到想象和想象到视频分别运行。情境 holdout 与数据集 holdout 把完整域作为组；当恰有三个域时，训练、验证和测试各持有一个域。

C.5 固定种子与分割审计

主表示审计使用 5 个固定种子。每个 assignment 文件均保存协议、种子、试次角色和对应 audit JSON。构建器检查 trial UID 唯一性、身份字段非空、分区角色合法，以及协议要求隔离的身份交集为零。模型只能在加载冻结 assignment 后应用标签和特征可用性掩码，避免因某种表示缺失而改变身份分配。

C.6 固定支持的身份暴露响应面

身份可用性不是单一二元变量。当前响应面显式改变两个有标签资源：每名目标参与者的完整校准试次数 (p)，以及每个测试刺激由其他参与者提供的评分 (s)。每个种子先生成严格的被试-刺激双重留出，再一次性筛选能支持预声明最大剂量的测试被试与刺激；随后所有 $((p,s))$ 单元共享同一组哈希固定测试 trial UID。低剂量样本是高剂量样本的确定性子集。

参与者校准试次来自目标参与者在非测试刺激上的记录，从不进入群体模型拟合；它们只估计模型拟合后的已知 ID 平均残差偏移。测试刺激评分来自非测试参与者，可以进入群体模型；每增加一行都会在相同情境内替换一个训练目标最近的 donor，因此群体训练集大小严格不变。该替换控制样本量，但不声称高阶身份图或目标分布获得因果匹配。MusicEEG 公开的规范刺激评分作为独立先验固定，不计入 (s)。当前响应面把目标参与者无标签数据固定为零，也不支持会话无关或跨设备结论。

每个单元由确定性规则编译声明卡：当 $(p>0)$ 时阻断“完全未见参与者”，当 $(s>0)$ 时阻断“未见刺激”，来源无图片 ID 时把刺激结论改为条件级，并始终阻断潜在情绪解耦与因果身份移除。该过程不依赖大语言模型自由生成判断。

D. EEG 表征与模型

D.1 透明频谱表示

核心透明表示使用 delta、theta、alpha、beta 和 gamma 频带的 DE 或 Welch 对数功率。全局视图对通道聚合，通道视图保留 channel-by-band 结构。所有标准化参数只在训练分区拟合；Ridge 正则强度以验证 MAE 选择，最终在训练加验证分区重拟合。频带与脑区消融包括单频带、留一频带、单脑区和留一脑区视图。脑区映射属于预测敏感性分析，不被解释为源定位或因果神经解剖结论。

D.2 CBraMod

官方 CBraMod checkpoint 与同架构随机初始化读取完全相同的 EmoEEG-MC 试次。每个 30 秒、64 通道、200 Hz 试次被组织为一秒 patch，encoder token 在通道和时间维平均池化为 200 维 trial 表征。源代码 commit、checkpoint SHA-256、输入 trial UID 与特征哈希随产物记录。下游只训练相同的预测头，不微调 encoder。

D.3 LaBraM

LaBraM 使用官方通道位置表和 base checkpoint。30 个一秒 patch 被切成三个 8-patch 窗和一个 6-patch 窗，以 patch 数加权汇总后得到 200 维 trial 表征。预训练专用 mask 与 decoder 头不参与下游特征，官方最终归一化路径保留。随机初始化对照实例化相同架构但不读取 checkpoint。

D.4 历史紧凑 EEGNet-style 网络

EEGNet 控制直接从 EmoEEG-MC 原始波形训练。输入经抗混叠重采样到 100 Hz；每个 epoch 从完整试次抽取一个确定性 10 秒训练 crop，验证与测试平均三个不重叠 crop 的预测。网络包含时间卷积、深度空间卷积、可分离时间卷积和八维 latent。其用途是检验冻结特征结论是否仅由 DE 或基础模型适配造成，而非进行针对每个数据集的穷尽架构搜索。

标准 Braindecode EEGNet 控制另见正文的实现敏感性分析，不能将此历史紧凑网络称为标准实现。

D.5 EMOD 原任务学习核验失败

另以官方 SEEDV 模型分支和 checkpoint 主干进行固定预算核验：62 通道、200 Hz、微伏单位、每窗一秒；每名参与者每个会话的前五、中五、后五个完整试次分别用于训练、验证和测试。48 个原始文件产生 117,744 个窗口，测试部分为 16 人的 240 个试次、40,352 个窗口。单一种子训练 100 轮，由验证 Kappa 选择 checkpoint，最终测试 balanced accuracy 为 0.20，Kappa 为 0，所有测试窗口均被预测为同一类别。输入哈希、测试身份、有限梯度和重算指标通过核验，但没有恢复原任务学习。

官方 SEEDV 代码分支使用较大的多层分类头，而论文描述线性分类器；论文没有完整给出每项任务最终选用的微调配方。这些复现条件差异需要进一步确认，不能凭本次失败否定原论文，也不能将冻结回归适配包装为完整 SOTA 复现。CUDA 池化反向存在非确定性实现，固定种子不等于逐位可重复；该边界随聚合训练日志记录。

EMOD 原任务数值故障修复。保留上述失败运行，在固定的 50 个训练窗口上执行配对诊断，每类十个，不依据验证或测试分数选择修复参数。分类头学习率为 $1e-3$ 时，第一次更新使首个全连接层输出标准差从约 0.773 增至 32.280；第 20 步，第二个隐藏层的 ELU 输出已经成为常量。官方 SEEDV 分类头先将 39,680 维特征展平，再映射至 2,480 维。保持架构、输入、初始化、优化器和主干学习率 $5e-4$ 不变，只将分类头学习率降至 $1e-5$ ，即可避免饱和，并在第 50 步拟合全部诊断训练样本。这说明当前配置存在可修复的数值故障，不是情绪机制结论。

全部 48 个训练标签文件与官方常量一致；从五个源文件中抽取的 100 个训练窗口，经官方相同预处理操作重算后，与既有 float32 输入逐值一致，其中包含格式回退和最高幅值的案例。这是抽查对齐，不是所有上游数据的独立真值验证。修复运行完成固定 100 轮，验证 Kappa 选择第 21 轮，然后仅评价一次测试集：balanced accuracy 为 38.62%，Kappa 为 0.2348，weighted F1 为 39.43%，五个类别均有预测。测试身份、输入哈希和指标均独立重算核验。

原论文表 2 的五次运行 BACC 为 $41.24 \pm 0.86\%$ ，本次单种子结果仍比该均值低 2.62 个百分点，不能称为统计等价或五种子完整复现。原任务是已见参与者下的分类，不是本文自评暴露响应面；没有同协议随机初始化对照，也不能将恢复分类能力解释为已证明预训练收益。修复保留源码、输入哈希、聚合激活轨迹和输入敏感性自动停止检查，旧失败结果不被覆盖。

E. 刺激先验、残差与去偏模型

E.1 三个预测器

1. **direct_eeg**: EEG 表征直接预测归一化效价与唤醒度。
2. **semantic_stimulus_prior**: 对小写 TF-IDF 描述一元/二元词组（最多 1,024 维、sublinear TF）以及名义类别、情境和源刺激强度码拟合 Ridge；每个训练刺激贡献一行群体均值目标，alpha 从 {0.01, 0.1, 1, 10, 100, 1000} 中按验证 MAE 选择。强度码不读取参与者评分。
3. **disentangled_prior_plus_eeg_residual**: 该名称是冻结结果注册表中的历史键名；已见刺激使用训练侧报告均值，未知刺激使用语义估计，先计算训练期留一测试刺激均值残差，再用 EEG 预测残差并与混合先验相加。它表示算术残差化，不声称潜在状态或因果解耦。

所有模型共享同一 assignment、目标和验证规则。先验分支与 EEG 分支分别报告，防止把刺激语义带来的性能归因给脑电。

E.2 去偏反事实

评估方法包括：训练期刺激中心分量减除；预测与刺激指示变量的条件协方差惩罚；保护响应方向后删除刺激子空间的线性投影；具有梯度反转刺激头的非线性残差网络；以及端到端 EEGNet 对抗版本。每种方法包含零强度设置，且对抗强度、投影维数和训练 epoch 仅根据验证残差 MAE 选择。测试时不使用刺激 ID 进行 EEG 残差预测。

成功标准不是单一 CCC 上升，而是目标性能、MAE、刺激效应量与身份探针共同改善。只降低预测方差、把验证选择推向零强度或在不同种子间方向不一致，均作为负结果报告。

F. 身份探针

数据集探针在 subject holdout 下使用全局频谱表示；刺激探针在 subject holdout 下于各数据集内部训练，并只评估训练阶段出现过的刺激类；被试探针在 stimulus holdout 下训练，并只评估训练阶段出现过的参与者。该设计分别回答来源域信息能否跨被试、刺激信息能否跨被试、以及参与者信息能否跨刺激迁移。

每个 probe 都保留同表示、同划分、同估计器的训练标签置换对照。balanced accuracy 是主指标，同时报告类别数、机会水平、测试覆盖率和每种子结果。LaBraM 预训练表征的被试身份 balanced accuracy 为 0.9642，随机初始化为 0.1733，均匀机会水平为 0.0333。十维 DE 特征的数据集身份 balanced accuracy 为 0.8987。

探针只证明身份信息可恢复。为检验其与预测行为的联系，我们在每个留刺激种子上以训练数据估计被试中心差异，经 SVD 得到身份方向，并依次移除 {0,1,2,4,8,16,24,29} 个方向；每个秩同时加入等秩 PCA 与带种子的随机正交方向作为一般降维对照。每个点重新拟合相同的语义、直接 EEG、残差和身份 probe，零移除为嵌套对照。该干预可能同时删除身份与真实情绪协变量，因此只解释为对线性可解码身份结构的干预。

G. 统计方法

连续预测报告 valence、arousal 及其 macro CCC、MAE 和 RMSE；身份任务报告 balanced accuracy，并在可用时附 macro-F1。模型比较在完全相同的 trial-level 预测上配对。历史非响应面分析先重采样评测种子，再重采样该种子内完整 held-out identity 簇，双重留出分别重采样被试和刺激因素；这些历史区间采用 2,000 次抽样。它不是本轮响应面的主要估计器。

5 个种子的精确双侧 sign-flip 检验最小可达非零 p 值为 0.0625。因而，本文使用 bootstrap 区间描述效应估计，把 sign-flip 结果作为有限种子功效说明，而不把传统显著性阈值作为选择性叙事门槛。

本轮身份暴露响应面使用 2,000 次共享参与者 $\times$ 刺激 bootstrap。身份在所有模型、单元和固定种子中共享抽样权重，不能因抽样退化就静默删除某个种子；有效抽样次数另行记录。主要统计为均匀网格上的匹配 EEG 增量平均值。端点效应、按剂量积分的 AUC、首次观测增益和排序变化为不同的次要估计量。五个种子不是五次独立研究复制。

历史重点审计包括支持匹配的身份重叠、被试子空间端点、LaBraM 留刺激预训练和外部条件先验对比。这些分析在基准开发期间选择，不能称为预注册确认。旧区间是逐比较区间；新版响应面在每个模型的命名增量剂量族内另给同时区间，不扩张为对全文所有比较的统一覆盖。

H. 补充结果解释

H.1 预训练的协议依赖性

LaBraM 预训练相对随机初始化在留刺激协议提高 0.0706，95% 区间为 [0.0396, 0.1143]，但在留被试与双重留出中差值为 0.0015 和 -0.0008。这支持留刺激设置下的额外预测收益，不确立主体不变的额外信息，也不证明其他设置下的收益不存在。

H.2 匹配对照与被试子空间干预

在测试 trial 与训练/验证行数匹配后，每个种子的测试集包含 32-56 个试次、4-7 名被试和 8 个刺激。恢复训练侧身份重叠使直接 EEG 的宏平均 CCC 相对双重留出提高 0.1511，区间为 [0.0349, 0.2156]；语义先验、混合先验与组合模型分别提高 0.0827、0.0991 和 0.2111，组合区间为 [0.1101, 0.2706]。最大被试方向移除把身份 balanced accuracy 降至 0.0342，组合模型 CCC 改变量为 -0.0656，交叉区间为 [-0.1070, -0.0272]；相对等秩 PCA 和随机方向的差分分别为 -0.0364 与 -0.0631，区间均不跨零。

语义先验组件消融显示，留刺激时移除名义类别使 CCC 相对完整先验下降 0.3049，区间 [0.2089, 0.3416]；双重留出中的对应下降为 0.4011，区间 [0.2557, 0.4591]。留被试时移除描述文本使 CCC 下降 0.0544，区间 [0.0384, 0.0710]。双重留出中，情境、强度代码和描述文本的独立贡献分别为 0.0012、-0.0100 和 -0.0129，区间均跨零。这些是预测组件消融，不是对真实刺激内容的因果干预。

H.3 外部条件分层

外部数据中，条件先验比 EEG-only 高 0.3457 CCC，95% 区间为 [0.3040, 0.3884]。条件先验相对通道级组合模型的 MAE 低 0.0134，区间为 [-0.0329, -0.0004]。条件身份可从 EEG 解码，但条件外残差没有稳定改善任何总体结论。该结果只支持留被试与条件级解释。

H.4 授权 SEED-V 案例：协议敏感性并非公开数据特有

SEED-V 作为用户已获授权、但不纳入公开基准的独立案例，只发布汇总审计记录，不发布原始 EEG、DE、刺激、试次预测或参与者标识。在原始时间序列的严格被试留出下，Raw 的 macro-F1 为 0.2418，SDSA 为 0.2297，差值为 -0.0121，95% 区间为 [-0.0439, 0.0178]；在更严格的被试-刺激联合留出下，二者分别为 0.1788 与 0.1856，差值为 0.0068，区间为 [-0.0154, 0.0292]。

同一案例中，严格时序划分下的 PaperStyle F1 为 0.2786，而随机试次式划分达到 0.5922；16 名严格测试参与者中只有 7 人使用 SDSA 后提高。Raw 与 SDSA 的被试身份 probe 分别为 0.7660

和 0.7901。该案例不被解释为某一方法的优劣结论，而是用于说明：协议改变可以远大于表示名称改变，且身份可解码性必须与情绪结果一起报告。

H.5 独立 MusicEEG 协议审计：严格泛化、身份信息与评分结构

为检验 EmoEEG-MC 的表征结论是否局限于视觉范式，我们在独立 MusicEEG 上预先固定五个完整 trial 划分，并只发布汇总结果。透明的通道对数频带功率 Ridge 在随机 trial、留被试、留音乐和被试-音乐双重留出下的 macro CCC 分别为 0.1031、0.0175、0.1130 和 0.0227；随机减双重留出的五种子配对差值为 0.0804，种子标准差为 0.0357。留音乐仍保留已知参与者，因此不能替代留被试；这一点在听觉范式中同样成立。

同一透明表征在未见音乐时识别训练中已见被试的 balanced accuracy 为 0.9995，标签置换为 0.0431，31 类均匀机会水平为 0.0323。相反，在未见被试的已见类别子集上识别音乐身份的 balanced accuracy 为 0.0000，置换为 0.0033；五个种子的测试覆盖率为 78.8–91.3%。这些 probe 只说明对应表征中可获得的身份信息，不证明情绪读出器因果地使用了该信息。

评分本身也限制解释边界。对同一音乐的其他参与者评分做留一预测时，效价与唤醒度的共识 CCC 分别为 0.1437 和 0.1634（各有 1,123 个受支持评分）。描述性的加性模型中，音乐身份 R-squared 为 0.3579 和 0.3484，高于被试身份的 0.1170 和 0.1782；这既不是重测信度/噪声上限，也不是主观体验的因果方差分解。

在同一四种协议下，我们将官方冻结 LaBraM 预训练编码器与同架构固定随机初始化比较，所有下游模型均为相同 Ridge 读出器。预训练与随机初始化的 macro CCC（差值）依次为：随机 trial 0.0923 对 0.0191（0.0732），留被试 0.0697 对 -0.0006（0.0703），留音乐 0.0847 对 0.0145（0.0703），双重留出 0.0422 对 0.0085（0.0337）。未见音乐的被试身份 probe 中，预训练为 0.9136，随机为 0.4239，标签置换分别为 0.0313 与 0.0297，接近 31 类机会水平 0.0323。这些点估计表明，预训练编码器在本次听觉范式评测中具有更高的自评预测分数；身份可解码性则是另一个表征属性，不证明预测器利用了身份。该结果不替代 EmoEEG-MC 中的支持匹配对照与表征扰动分析，不证明可迁移的个体情绪已被解耦，也不支持“主体不变情绪表示”的一般化结论。

H.6 身份暴露响应面的跨范式差异

以下区间为旧版本的逐种子统计，仅用于追溯，不是当前主结论。当前共享身份重采样结果见正文：MusicEEG 的联合资源效应区间跨零；ds006866 每个划分只有一个测试条件，不能据旧区间宣称总体新条件泛化。

预训练 LaBraM 在 EmoEEG-MC 上的参与者校准、刺激暴露和联合端点增量分别为 0.1788 [0.0712, 0.2307]、0.4728 [0.2900, 0.5420] 和 0.5800 [0.4072, 0.6219]。MusicEEG 对应值为 0.0953 [-0.0097, 0.2037]、0.1060 [-0.0950, 0.2798] 和 0.2045 [0.0157, 0.3320]。ds006866 的 band-power 参与者校准、条件暴露与联合效应分别为 0.2856 [0.2132, 0.3461]、-0.0014 [-0.0071, 0.0042] 和 0.3256 [0.2694, 0.3685]。三个范式的响应形状不同，说明“资源可用”不能由一个 subject-independent 标签替代。

DENS 只有 4 个种子满足预声明的固定支持规则，固定测试集仅含 5–10 个试次；种子 11 被标记为 `blocked_by_fixed_support`，所有效应区间均跨零。因此 DENS 只用于暴露工具能否处理缺失与阻断状态的补充演示，不作为跨范式正向复制。

I. 发布与复现边界

匿名公开包包含代码、测试、配置、评测卡、数据卡、Croissant、论文表格源与数值 claim 配置。以下内容明确排除：原始 EEG、源 DE/特征数组、foundation checkpoint、电影、音乐、图片、Office 文件、Git 历史和机器本地路径。

复现模式分为：

- **metadata**: 不读取数据，验证基准契约、Croissant 与评测卡。
- **smoke**: 使用合成 trial 数据运行分割、基线、probe 和小型注册表。
- **full**: 要求用户显式提供已获取的数据根目录，核验冻结输入哈希和重建论文资产。
- **recomputeplan/run**: 展示或执行原始 trial 构建、特征提取、模型评估、probe、统计与论文编译的有类型依赖图；`--resume` 仅在所有声明输出均存在时跳过步骤。

full 验证冻结结果并不等价于重新下载和多日冷启动训练。现有 `clean-environment` 复现由同一服务器上的隔离环境完成，也不被表述为独立实验室复现。

J. 补充表与机器可读附件

J.1 表 S1: 数据集与协议状态矩阵

数据集	trial-random	留被试	留刺激	双重留出	方向性跨情境	留数据集
MusicEEG	支持	支持	支持	支持	不适用	支持
DENS	支持	支持	支持	支持	不适用	支持
EmoEEG-MC	支持	支持	支持	支持	支持	支持
ds006866	支持	支持	源元数据阻塞	源元数据阻塞	支持	不适用

表 S1 的逐单元英文原因直接来自 [cards/evaluations/evaluation_matrix.tsv](#)。其中“源元数据阻塞”与模型失败不同：科学问题适用，但公开事件表缺少构造该协议所需的 trial 级图片身份。

J.2 表 S2：数据构成与可用性

表 S2 由 [paper/generated/table_benchmark_scope.csv](#) 自动渲染，字段固定为数据集、层级、参与者记录数、重建试次数、完整目标试次数、刺激身份数与刺激身份状态。汇总行应显示核心层的 3 个数据集、131 名数据集内合格参与者、4,135 个重建试次、369 个合格刺激身份和 2,865 个完整目标试次，以及全部 4 个数据集的 279 名参与者、39,642 个重建试次和 38,369 个完整目标试次。

排除原因不压缩成单一“缺失”类别：MusicEEG 标记刺激映射为 `audited_inference`；DENS 分开记录行为标签缺失、刺激来源映射缺口和不可读信号；EmoEEG-MC 区分全部重建试次与经全局刺激码核验的监督子集；ds006866 明确记录刺激身份字段缺失。最终表格保留这些状态的完整英文值，不以脚注隐藏。

J.3 表 S3：表示与训练状态

表示	输入单元	输出/视图	预训练对照	下游状态	主要审计边界
DE / Welch 频带	完整 trial 后的频带统计	全局、通道、频带与脑区消融	不适用	验证集选择 Ridge	训练期拟合标准化；不作源定位解释
CBraMod	EmoEEG-MC 的 64 通道、200 Hz、30 秒 trial	冻结 trial embedding	官方 checkpoint 与同架构固定随机初始化	编码器冻结	相同 trial、相同划分
LaBraM	官方通道位置与一秒 patch	patch 数加权 trial embedding	官方 base checkpoint 与同架构固定随机初始化	编码器冻结	排除预训练 mask/decoder；保留最终归一化
EEGNet	重采样后的原始 trial crop	八维 latent 与情绪预测	零对抗与验证所选对抗设置	端到端训练	只作为双重留出专用网络控制

表 S3 的 checkpoint 哈希、源 commit、crop/patch 参数和模型许可分别从 [cards/models/*.md](#)、特征 sidecar 与冻结结果文件填充；匿名包不包含权重。

J.4 表 S4：关键配对比较

比较	协议	CCC 差值	层次 bootstrap 95% 区间	解释边界
LaBraM 预训练 - 随机初始化	留刺激	0.0706	[0.0396, 0.1143]	已知参与者面对新刺激
LaBraM 预训练 - 随机初始化	留被试	0.0015	区间跨 0	新参与者

比较	协议	CCC 差值	层次 bootstrap 95% 区间	解释边界
LaBraM 预训练 - 随机初始化	双重留出	-0.0008	区间跨 0	新参与者与新刺激
身份重叠 - 双重留出 (直接 EEG)	匹配测试与样本量	0.1511	[0.0349, 0.2156]	EEG 分支敏感性
身份重叠 - 双重留出 (组合管线)	匹配测试与样本量	0.2111	[0.1101, 0.2706]	先验与残差共同变化
身份方向 - 等秩 PCA	留刺激	-0.0364	[-0.0624, -0.0118]	方向特异性
身份方向 - 等秩随机方向	留刺激	-0.0631	[-0.1028, -0.0263]	方向特异性
最大被试方向移除 - 零移除	留刺激	-0.0656	[-0.1070, -0.0272]	LaBraM 身份子空间干预
条件先验 - EEG-only	ds006866 留被试	0.3457	[0.3040, 0.3884]	新参与者、条件可重复

上述数值由 [paper/generated/table_representation_comparisons.csv](#)、[paper/generated/table_reviewer_controls.csv](#) 和 [paper/generated/table_external_validation.csv](#) 生成。全部模型对、MAE 差值、区间和精确 sign-flip 结果保留在注册表与审稿控制表中，避免在 PDF 中选择性截取大量次要比较。5 种子检验的最小可达非零 p 值为 0.0625。

J.5 表 S5：身份探针摘要

表示与任务	观测 balanced accuracy	均匀机会水平	协议含义
LaBraM 预训练, 被试 ID	0.9642	0.0333	未见刺激
LaBraM 随机初始化, 被试 ID	0.1733	0.0333	未见刺激
DE, 数据集 ID	0.8987	0.3333	未见被试
LaBraM 预训练, 刺激 ID	0.0234	0.0238	未见被试
ds006866 通道频带, 条件 ID	0.2486	0.1667	未见被试
ds006866 全局频带, 条件 ID	0.2134	0.1667	未见被试

表 S5 来自 [paper/generated/table_identity_probes.csv](#) 与 [paper/generated/table_external_validation.csv](#)。最终英文表同时渲染每一行的置换标签结果，但不在中文母稿中手工复制尚未进入 claim ledger 的数值。每种子的明细保留在 [paper/generated/table_identity_probe_seeds.csv](#)；频带和脑区敏感性使用完整注册表作为机器可读附件，不把脑区预测差异解释为神经源定位。

J.6 ds006866 v2 完整外部审计

下表给出 5 个固定种子的 macro-CCC 均值。BP 为 320 维通道频带功率，Pre. 与 Rand. 分别为冻结预训练 LaBraM 和匹配随机初始化，Hybrid 为可迁移条件族先验加 EEG 残差。

协议	先验	EEG BP	EEG Pre.	EEG Rand.	Hybrid BP	Hybrid Pre.	Hybrid Rand.
留参与者	0.3776	0.0369	0.0335	0.0198	0.3425	0.3742	0.3797
非社会 → 社会，参与者重复	0.3757	0.2319	0.2604	0.2539	0.5144	0.5507	0.5476
社会 → 非社会，参与者重复	0.3780	0.2226	0.2526	0.2455	0.5116	0.5486	0.5462
非社会 → 社会，留参与者	0.3704	0.0208	0.0323	0.0152	0.3318	0.3718	0.3726
社会 → 非社会，留参与者	0.3792	0.0172	0.0289	0.0220	0.3472	0.3761	0.3844

参与者重复时，三种表示在两个方向的 hybrid 相对先验 MAE 改善均有 5/5 个参与者簇区间低于零；联合留出下，LaBraM hybrid 没有建立稳定的先验外改善。两个联合方向的预训练减随机 hybrid CCC 分别为 -0.0008 和 -0.0082，且都只有 2/5 个种子为正。

身份探针单元格为“观测/置换”balanced accuracy，机会水平由拟合类别数决定。

协议	探针	BP	Pretrained	Random	机会水平
留参与者	6 类条件	0.2448/0.1669	0.1713/0.1667	0.1675/0.1653	0.1667
非社会 → 社会，参与者 参与者重复		0.9910/0.0066	0.9997/0.0074	0.9963/0.0057	0.0068
社会 → 非社会，参与者 参与者重复		0.9890/0.0063	0.9999/0.0045	0.9973/0.0046	0.0068
非社会 → 社会，条件族 留参与者		0.4091/0.3238	0.3399/0.3317	0.3306/0.3333	0.3333

协议	探针	BP	Pretrained	Random	机会水平
社会 → 非社会, 条件族 留参与者		0.4206/0.3268	0.3384/0.3336	0.3308/0.3315	0.3333

近乎完美的跨情境参与者探针只证明身份信息可被固定线性读出，不证明情绪头因果使用身份。148 个记录均包含相同顺序的 64 个 EEG 通道；146 个符合基础模式，2 个只多出预先声明排除的 EMG 通道。

J.7 表 S7: 身份暴露响应面摘要

数据集	表征	零资源 CCC	最大资源 CCC	响应面 AUC	参与者增量 [95% 区间]	刺激/条件 增量 [95% 区间]	联合增量 [95% 区间]
EmoEEG- MC	预训练 LaBraM	-0.0052	0.5748	0.4604	0.1788 [0.0712, 0.2307]	0.4728 [0.2900, 0.5420]	0.5800 [0.4072, 0.6219]
MusicEEG	预训练 LaBraM	0.1026	0.3070	0.2302	0.0953 [-0.0097, 0.2037]	0.1060 [-0.0950, 0.2798]	0.2045 [0.0157, 0.3320]
ds006866	全局 band power	—	—	—	0.2856 [0.2132, 0.3461]	-0.0014 [-0.0071, 0.0042]	0.3256 [0.2694, 0.3685]